Processamento de Linguagem Natural

Episode III : Semântica Vetorial

Alex Marino

12 de março de 2026

Conteúdo

Overview

Semântica Léxica

Semântica Vetorial

Palavras e Vetores

Evolução Paralela: Smilodon e Thylacosmilus

- O asfalto de Los Angeles preserva fósseis da Era do Gelo, como o Smilodon (tigre-dente-de-sabre).
- Há 5 milhões de anos, o Thylacosmilus, um marsupial da América do Sul, também tinha longos caninos superiores.
- Ambos compartilhavam características similares, como a flange óssea na mandíbula inferior.
- Exemplo de evolução paralela: estruturas similares em espécies diferentes devido a contextos ambientais (Gould, 1980).

Hipótese Distribucional e Semântica Vetorial

- Palavras em contextos similares têm significados similares (hipótese distribucional).
- Formulada por linguistas como Joos (1950), Harris (1954) e Firth (1957).
- Exemplo: palavras sinônimas (como "oculista"e "oftalmologista") aparecem em ambientes semelhantes.
- Harris (1954): a diferença de significado entre palavras reflete a diferença em seus contextos.

Embeddings e Aprendizado de Representação

- Semântica vetorial: representações de palavras (embeddings) aprendidas a partir de distribuições textuais.
- Embeddings capturam o significado dinâmico e contextual das palavras.
- Exemplo: BERT utiliza aprendizado de representação para codificar texto.
- Aprendizado auto-supervisionado: representações úteis são aprendidas automaticamente, sem engenharia manual (Bengio et al., 2013).

DERIVADA
sema
ANTONIMIA
PARASINTÉTICA
PARASINTÉTICA
COMPUESTA
SINONIMIA
POLISEMIA
ANTONIMIA
sema
homoninia
familia
PARASINTÉTICA
COMPUESTA
léxica
POLISEMIA
significado
acronimia
familia
homoninia
SINONIMIA
homoninia
COMPUESTA
semema
sigla
DERIVADA
POLISEMIA
significado
léxica
acronimia
semema
SIMPLE
DERIVADA
SINONIMIA
SIMPLE
ANTONIMIA
familia
sigla
semema
SIMPLE
SINONIMIA
COMPUESTA
PARASINTÉTICA
POLISEMIA

Introdução à Semântica Lexical

- Semântica lexical: estudo do significado das palavras e suas relações.
- Representação tradicional: palavras como sequências de letras (ex.: "dog"como DOG).
- Problema: não captura o significado real (Carlson, 1977).
- Objetivo: criar modelos que representem o significado de forma mais rica.
- Exemplo: "What's the meaning of life?"– significados variam por contexto.

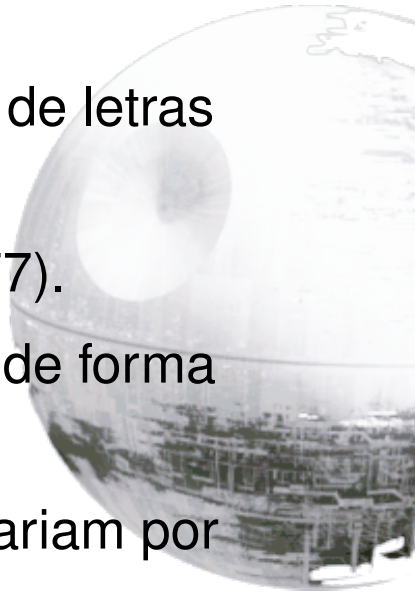

Relações Semânticas e Hiperônimos

- **Lemmas e Formas**: "Mouse"pode ser um roedor ou dispositivo (WordNet).
- **Sinônimos**: Palavras com significados idênticos ou próximos (ex.: "couch/sofa").
- **Hiperônimos e Hipônimos**: "Mouse"(roedor) é hipônimo de "animal".
- **Relações de Similaridade**: Palavras como "cat"e "dog"compartilham traços (SimLex-999 dataset).
- Exemplo de valores semânticos (SimLex-999):

Pares de Palavras	Similaridade
vanish/disappear	9.8
belief/impression	5.95
muscle/bone	3.65
modest/flexible	0.98
hole/agreement	0.3

Relações Semânticas e Hiperônimos

- **Lemmas e Formas**: "Mouse"pode ser um roedor ou dispositivo (WordNet).
- **Sinônimos**: Palavras com significados idênticos ou próximos (ex.: "couch/sofa").
- **Hiperônimos e Hipônimos**: "Mouse"(roedor) é hipônimo de "animal".
- **Relações de Similaridade**: Palavras como "cat"e "dog"compartilham traços (SimLex-999 dataset).
- Exemplo de valores semânticos (SimLex-999):

Pares de Palavras	Similaridade
vanish/disappear	9.8
belief/impression	5.95
muscle/bone	3.65
modest/flexible	0.98
hole/agreement	0.3

Representações Vetoriais e Dimensões do Significado

- **Semântica Vetorial**: Palavras representadas como vetores (ex.: embeddings).
- Osgood et al. (1957): significado em 3 dimensões:
  - Valência: prazer (ex.: happy = alta, sad = baixa).
  - Arousal: intensidade emocional (ex.: excited = alta, calm = baixa).
  - Dominância: controle (ex.: controlling = alta, awed = baixa).
- Exemplo de valores:

Palavra	**Valência**	**Arousal**	**Dominância**
courageous	8.05	5.5	7.38
music	8.67	5.57	6.5
heartbreak	2.45	5.65	3.58
cub	6.71	3.95	4.24

Relação entre Palavras (Word Relatedness)

- **Definição**: Palavras podem estar relacionadas de formas além da similaridade.
- Exemplo (Budanitsky e Hirst, 2006):
  - "coffee"e "cup"estão relacionados (associação), mas não são sinônimos.
  - "coffee"(bebida) e "beverage"(hiperônimo) também estão relacionados.
- **Aplicação**: Modelos de linguagem capturam essas relações (ex.: embeddings).
- Exemplo prático: "scalpel"e "surgeon"(associação em contexto médico).

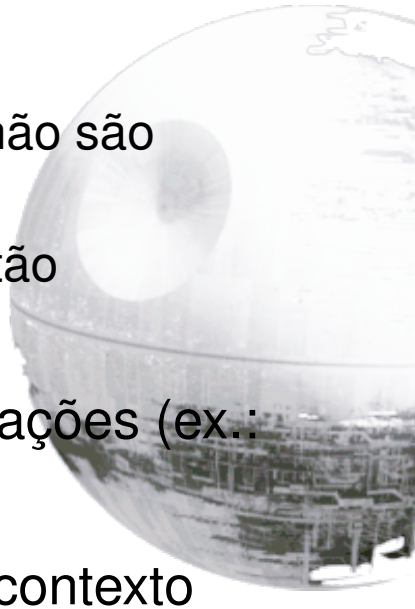

Campo Semântico e Tema (Topic)

- **Campo Semântico**: Conjunto de palavras relacionadas por um domínio.
  - Ex.: "hospital", "doctor", "nurse", "scalpel"(campo semântico: medicina).
- **Tema (Topic)**: Assunto geral que conecta palavras em um texto.
  - Ex.: "restaurante"$\rightarrow$ palavras como "waiter", "menu", "chef".
- **Aplicação**: Modelos como LDA (Latent Dirichlet Allocation) identificam temas em textos.

Frame Semântico e Regras Semânticas

- **Frame Semântico**: Estrutura que representa uma situação com papéis semânticos.
  - Ex.: Transação comercial $\rightarrow$ papéis: "buyer", "seller", "goods", "money".
  - "buy"(comprador) e "sell"(vendedor) compartilham o frame de transação.
- **Regras Semânticas**: Regras que definem relações e restrições de significado.
  - Ex.: "buy"implica um "buyer"(comprador) e "goods"(bens).
- **Aplicação**: Ajuda na tradução automática e interpretação de frases.

Resumo e Aplicações

- **Relação entre Palavras**: Conexões além da similaridade (ex.: "coffee"e "cup").
- **Campo Semântico**: Palavras agrupadas por domínio (ex.: medicina).
- **Tema (Topic)**: Assunto geral de um texto (ex.: restaurante).
- **Frame Semântico**: Estrutura de papéis em uma situação (ex.: transação).
- **Aplicações em NLP**:
  - Modelagem de temas (LDA).
  - Tradução automática e interpretação de papéis semânticos.

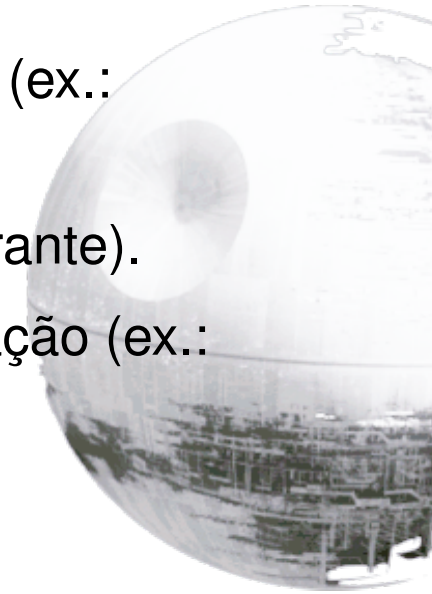

Resumo e Aplicações

- **Wordform e Lemma**: Diferencia formas e significados base.
- **Synonym**: Identifica palavras com significados próximos.
- **Princípio do Contraste**: Garante distinção entre significados.
- **Similaridade**: Mede proximidade semântica entre palavras.
- **Aplicações em NLP**:
  - Busca semântica (ex.: encontrar sinônimos).
  - Sumarização e tradução automática.
  - Modelos de linguagem (ex.: embeddings para capturar similaridade).

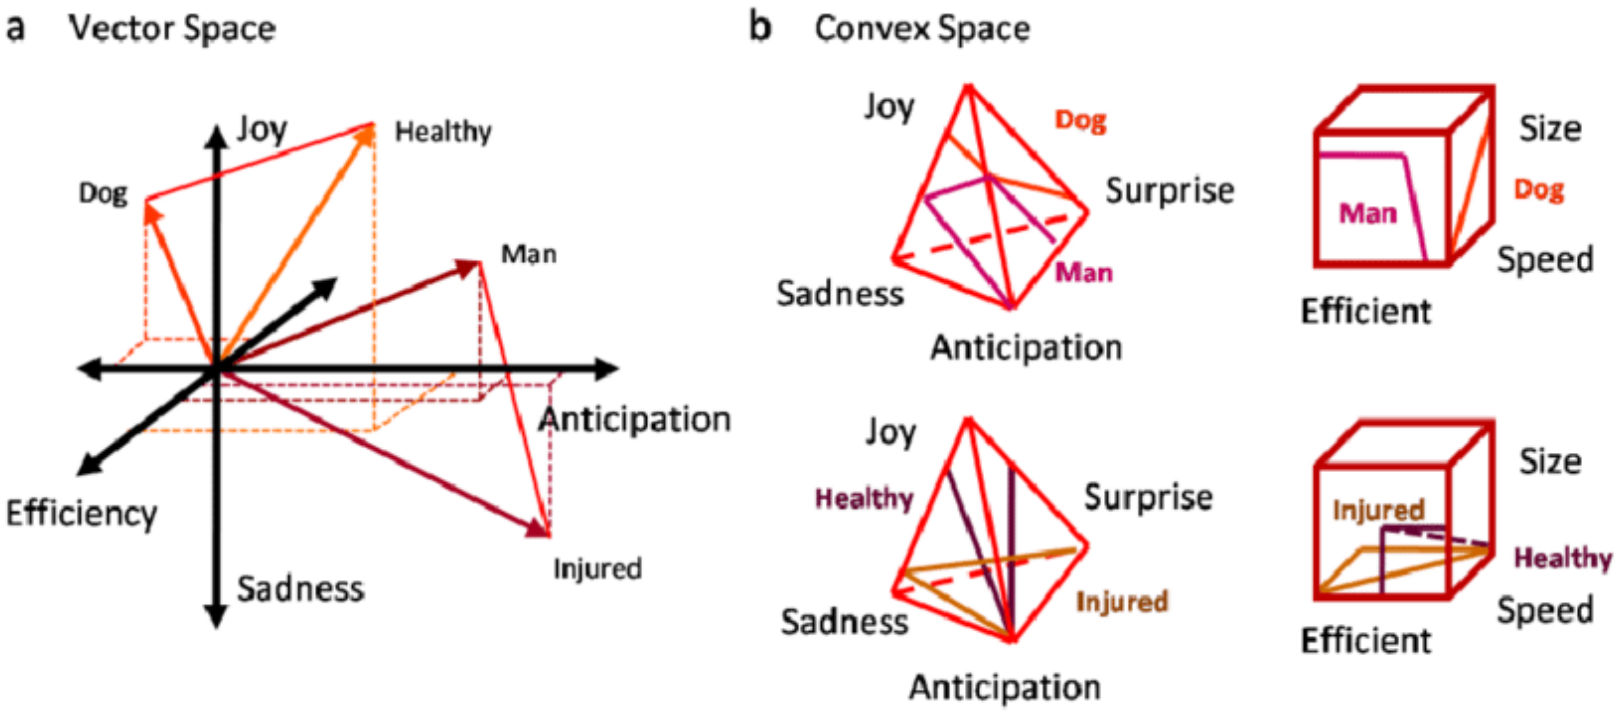
a Vector Space
Joy
Healthy
Dog
Man
Anticipation
Efficiency
Injured
Sadness
b Convex Space
Joy
Dog
Surprise
Sadness
Man
Anticipation
Size
Dog
Man
Speed
Efficient
Joy
Healthy
Surprise
Sadness
Injured
Anticipation
Size
Injured
Healthy
Speed
Efficient

Semântica Vetorial / Espaço Semântico

- É uma abordagem em linguística computacional e processamento de linguagem natural (NLP) que representa palavras, frases ou textos como vetores numéricos em um espaço multidimensional.
- Esses vetores, chamados de embeddings, são gerados de forma que a posição de cada palavra no espaço vetorial reflita seu significado semântico, capturando relações como similaridade, analogia e contexto.

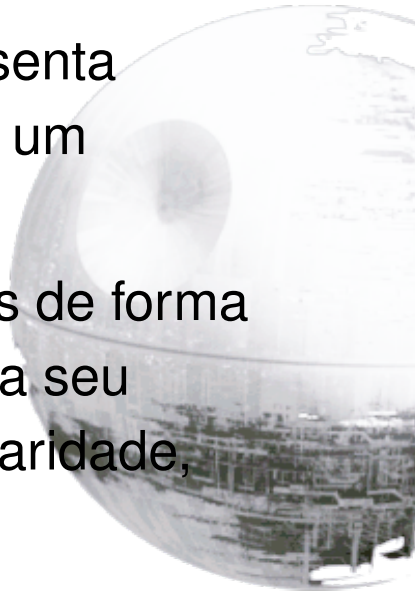

Semântica Vetorial

Definição

Na semântica vetorial, o significado de uma palavra é inferido a partir de sua distribuição em um corpus de texto, seguindo a hipótese distribucional (palavras que aparecem em contextos similares têm significados similares). Modelos como **Word2Vec**, **GloVe** e **BERT** transformam palavras em vetores de números reais (ex.: [0.5, -0.2, 0.8, ...]), onde:

- A proximidade entre vetores indica similaridade semântica (ex.: "gato"e "cachorro"terão vetores próximos).
- Operações vetoriais podem capturar relações, como analogias (ex.: "rei- "homem"+ "mulher" "rainha").

Exemplo

- No texto fornecido, a semântica vetorial é mencionada no contexto de embeddings, que aprendem representações a partir de distribuições textuais.
- Por exemplo, o modelo BERT (mencionado no Capítulo 11 do texto) usa embeddings contextuais, onde o vetor de uma palavra como "mouse"varia dependendo se o contexto é sobre um roedor ou um dispositivo.

Aplicação

- A semântica vetorial é amplamente usada em tarefas de NLP:
  - como busca semântica
  - tradução automática
  - análise de sentimentos
- Permitindo que máquinas compreendam e manipulem significados de forma mais próxima à cognição humana.

Vetor

- Modelos vetoriais ou distribucionais de significado são geralmente baseados em uma matriz de coocorrência, uma forma de representar com que frequência as palavras ocorrem juntas.
- Vamos analisar duas matrizes populares:
  1. a matriz termo-documento,
  2. matriz termo-termo.

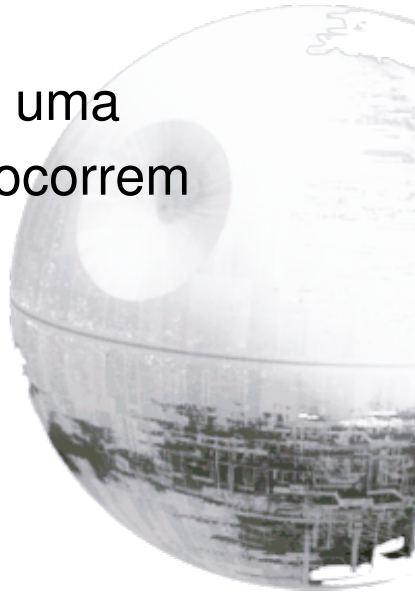

Definições

- **Matriz de coocorrência**: Uma estrutura de dados que registra a frequência com que palavras aparecem juntas em um determinado contexto (ex.: dentro de um documento ou em uma janela de palavras).
- **Matriz termo-documento**: Representa a frequência de termos (palavras) em diferentes documentos. Cada linha é um termo, e cada coluna é um documento.
- **Matriz termo-termo**: Representa a frequência com que dois termos aparecem juntos em um contexto (ex.: dentro de uma janela de palavras em um texto). Cada linha e coluna representa um termo.

Vetores e documentos

- A **matriz termo-documento** é uma estrutura fundamental no modelo de espaço vetorial. Ela representa a relação entre termos (palavras) e documentos em um corpus (coleção de documentos). Aqui está como ela funciona:
  - **Linhas**: Representam os termos (palavras) do vocabulário do corpus.
  - **Colunas**: Representam os documentos do corpus.
  - **Valores**: Representam a frequência (ou peso) de um termo em um documento.
  - Esse peso pode ser:
    - A frequência bruta (quantas vezes o termo aparece no documento).
    - Um valor ajustado, como o TF-IDF (Term Frequency-Inverse Document Frequency), que dá mais peso a termos raros e menos peso a termos muito comuns (ex.: "de", "o").

Modelo de Espaço Vetorial (Vector Space Model - VSM)

- O modelo de espaço vetorial usa a matriz termo-documento para representar documentos e consultas (queries) como vetores em um espaço multidimensional.
- A ideia é que documentos com vetores "próximos"(em termos de similaridade, como a similaridade cosseno) são semanticamente relacionados.

Similaridade coseno

- Mede o ângulo entre dois vetores, ignorando a magnitude (tamanho) dos vetores. A fórmula é:

$$sim(A, B) = \frac{A.B}{||A||||B||} \tag{1}$$

Onde $A.B$ é o produto escalar e $||A||||A||$ é a norma entre os vetores.

Exemplo

- Dado o exemplo:
  - DOC1 = [1, 1, 0, 0]
  - DOC2 = [1, 0, 1, 0]
-

$$Sim(D1, D2) = \frac{(1 \times 1) + (1 \times 0) + (0 \times 1) + (0 \times 0)}{\sqrt{1^2 + 1^2 + 0^2 + 0^2 +} \times \sqrt{1^2 + 0^2 + 1^2 + 0^2 +}} = \frac{1}{\sqrt{2} \times \sqrt{2}} = 0.5 \quad (2)$$

Exemplo

	pie	data	computer
cherry	442	8	2
digital	5	1683	1670
information	5	3982	3325

$$\cos(\text{cherry}, \text{information}) = \frac{442 * 5 + 8 * 3982 + 2 * 3325}{\sqrt{442^2 + 8^2 + 2^2}\sqrt{5^2 + 3982^2 + 3325^2}} = .018$$

$$\cos(\text{digital}, \text{information}) = \frac{5 * 5 + 1683 * 3982 + 1670 * 3325}{\sqrt{5^2 + 1683^2 + 1670^2}\sqrt{5^2 + 3982^2 + 3325^2}} = .996$$

TFIDF

- O **TF-IDF** é uma métrica que combina dois fatores para determinar a relevância de um termo (palavra) em um documento dentro de um corpus (coleção de documentos):
  - **TF (Term Frequency)**: A frequência do termo no documento, ou seja, quantas vezes o termo aparece no documento.
  - **IDF (Inverse Document Frequency)**: A frequência inversa do documento, que mede a raridade do termo no corpus, dando mais peso a termos que aparecem em poucos documentos.

Term Frequency

- O TF representa a frequência de um termo t em um documento d. No texto, duas formas de calcular o TF são apresentadas:
- **Frequência Bruta:** A forma mais simples é usar a contagem direta do termo no documento:

$$tf_{t,d} = count(t, d) \tag{3}$$

Exemplo: Se a palavra "Romeo"aparece 5 vezes em um documento, então $tf_{Romeo,d} = 5$

Term Frequency

- Frequência Logarítmica : Para evitar que termos muito frequentes dominem (ex.: uma palavra que aparece 100 vezes não é necessariamente 100 vezes mais importante que uma que aparece 1 vez), o texto sugere usar uma escala logarítmica:

$$\mathrm{tf}_{t,d} = \begin{cases} 1 + \log_{10}(\mathrm{count}(t,d)) & \text{if } \mathrm{count}(t,d) > 0 \\ 0 & \text{otherwise} \end{cases} \tag{4}$$

Explicação

- Explicação: O logaritmo "comprime"a frequência, reduzindo o impacto de contagens muito altas.

  Exemplo:

  Se $count(t, d) = 0$ então $tf_{t,d} = 0$

  Se $count(t, d) = 1$ então $tf_{t,d} = 1 + log_{10}1 = 1 + 0 = 1$

  Se $count(t, d) = 10$ então $tf_{t,d} = 1 + log_{10}10 = 1 + 1 = 2$

  Se $count(t, d) = 100$ então $tf_{t,d} = 1 + log_{10}100 = 1 + 2 = 3$

- Essa abordagem logarítmica é mais comum porque reflete melhor a relevância relativa de um termo.

Inverse Document Frequency(IDF)

- O IDF mede a raridade de um termo no corpus, dando mais peso a termos que aparecem em poucos documentos (termos discriminativos) e menos peso a termos que aparecem em muitos documentos (termos comuns). A fórmula apresentada no texto é:

$$idf_t = log_{10} \times (\frac{N}{df_t}) \tag{5}$$

N = número total de documentos do corpus

df_t = número de documentos que contêm o termo t

Exemplo do Texto (Corpus de Shakespeare)

- O texto usa um corpus com 37 peças de Shakespeare (N=37).
- A tabela fornecida mostra a frequência de documentos (df) e o IDF para algumas palavras:

  "Romeo" : $df = 1$, $idf = log_{10}(37/1) = 1.57$

  "salad" : $df = 2$, $idf = log_{10}(37/2) = 1.27$

  "Falstaff" : $df = 4$, $idf = log_{10}(37/4) = 0.967$

  "good" : $df = 37$, $idf = log_{10}(37/37) = 0$

TFIDF

- O TF-IDF é o produto do TF e do IDF, dando um peso final para cada termo em cada documento:

$$w_{t,d} = tf_{t,d} \times idf_t \tag{6}$$

$w_{t,d}$: Peso do termo no documento d

$w_{t,d}$: Peso do termo no documento d,

Termos com alta frequência em um documento (alto TF) e que são raros no corpus (alto IDF) recebem os maiores pesos.

Exemplo do Texto (Matriz Termo-Documento com TF-IDF)

- O texto apresenta uma matriz termo-documento ponderada por TF-IDF para 4 palavras em 4 peças de Shakespeare (usando $tf = 1 + log_{10}(count)$ e $idf = 0.37$)

	As You Like It	**Twelfth Night**	**Julius Caesar**	**Henry V**
battle	0.246	0	0.454	0.520
good	0	0	0	0
fool	0.030	0.033	0.012	0.019
wit	0.085	0.081	0.048	0.054

Tabela: Valores de TF (Term Frequency) para termos em diferentes obras

Análise

- "good"tem idf=0 (porque aparece em todas as peças), então seu peso TF-IDF é 0 em todos os documentos.
- "battle"tem um IDF mais alto (0.37) e aparece com maior frequência em "Henry V"e "Julius Caesar", resultando em pesos mais altos (0.520 e 0.454).
- "fool"e "wit"têm pesos menores porque, embora sejam menos comuns que "good", ainda aparecem em várias peças, reduzindo seu IDF.

Por que usar TFIDF

- O texto destaca os problemas de usar apenas a frequência bruta (raw frequency):
  - Frequência bruta é enviesada: Palavras como "the", "it"ou "they"aparecem muito em todos os documentos, mas não são informativas.
  - Frequência bruta não é discriminativa: No exemplo de Shakespeare, a palavra "good"tem alta frequência em todas as peças, mas não ajuda a distinguir uma peça da outra (não é discriminativa).

Por que usar TFIDF

- TF captura a importância de um termo dentro de um documento.
- IDF dá mais peso a termos raros, que são mais úteis para distinguir documentos.
- Exemplo do Texto: Para distinguir "cherry"de "strawberry"(frutas) e "digital"de "information"(tecnologia), o TF-IDF ajuda a focar em termos raros e específicos, ignorando palavras comuns como "the".

Aplicações

- O TF-IDF é amplamente usado em:
- Recuperação da Informação: Para ranquear documentos com base em uma consulta (query).
- Documentos com termos raros e relevantes para a consulta recebem maior pontuação.
- Modelos Vetoriais: Como base para representar documentos em um espaço vetorial, onde a similaridade entre documentos (ou entre um documento e uma consulta) pode ser calculada (ex.: usando similaridade cosseno).
- Outras Tarefas de NLP: Classificação de texto, clustering de documentos, e mais.

Pointwise Mutual Information (PMI)

- O que é Pointwise Mutual Information (PMI)?

  A Pointwise Mutual Information (PMI) é uma métrica estatística usada em processamento de linguagem natural (NLP) para medir a associação entre dois eventos, como a coocorrência de duas palavras em um corpus de texto.

- No contexto de semântica vetorial, o PMI é aplicado para quantificar o quanto a ocorrência de uma palavra está relacionada à ocorrência de outra palavra, em comparação com a probabilidade de ocorrerem independentemente.

- O PMI é especialmente útil em matrizes de coocorrência (como a matriz termo-termo), onde queremos capturar relações semânticas entre palavras com base em sua frequência de coocorrência, ajustando para o fato de que palavras comuns tendem a coocorrer mais frequentemente por acaso.

Definição e fórmula

- O PMI entre duas palavras w_1 w_2 é definido como o logaritmo da razão entre a probabilidade conjunta de coocorrência das duas palavras e o produto das suas probabilidades individuais (assumindo independência). A fórmula é:

$$PMI(w_1, w_2) = log_2(\frac{P(w_1, w_2)}{P(w_1)P(w_2)}) \tag{7}$$

$P(w_1, w_2)$: Probabilidade de w_1, w_2 coocorrerem juntas (em um contexto definido, como uma janela de palavras).

$P(w_1)$: Probabilidade de w_1 ocorrer sozinha.

$P(w_2)$: Probabilidade de w_2 ocorrer sozinha.

O logaritmo na base 2 é comumente usado.

Interpretação

- **PMI > 0**: As palavras coocorrem mais frequentemente do que o esperado se fossem independentes, indicando uma associação positiva (ex.: "gato"e "rato"podem ter um PMI alto se aparecem juntos com frequência).
- **PMI = 0**: As palavras coocorrem na frequência esperada sob independência (sem associação especial).
- **PMI < 0**: As palavras coocorrem menos frequentemente do que o esperado, indicando uma associação negativa (ex.: "gato"e "computador"podem ter PMI negativo se raramente aparecem juntos).

Como Calcular o PMI em um Corpus

- Para calcular o PMI, precisamos de uma matriz de coocorrência termo-termo, que registra quantas vezes duas palavras aparecem juntas em um contexto (ex.: dentro de uma janela de 5 palavras).
- Vamos detalhar o processo com um exemplo:

  Imagine um pequeno corpus com 1000 palavras no total, e consideramos as palavras "gato"e "rato":
- "gato"aparece 50 vezes $(count(gato) = 50)$
- "gato"aparece 30 vezes $(count(gato) = 30)$
- "gato"e "rato"coocorrem 20 vezes $(count(gato) = 50)$

Calculando PMI

- $P(gato) = \frac{count(gato)}{\text{total palavras}} = \frac{50}{100} = 0.5$
- $P(rato) = \frac{count(gato)}{\text{total palavras}} = \frac{30}{100} = 0.3$
- $P(gato, rato) = \frac{count(gato)}{\text{total coocorrencias}} = \frac{20}{5000} = 0.004$

obs : Suponha que o total de pares de coocorrências no corpus seja 5000 (considerando todas as janelas de palavras)

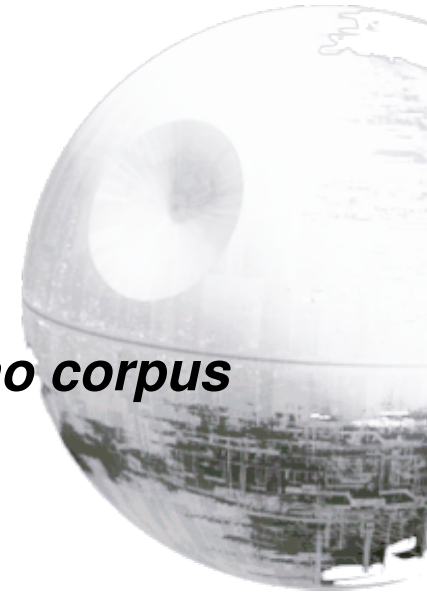

Calculando PMI

$$PMI(gato, rato) = log_2(\frac{P(gato,rato)}{P(gato) \times P(rato)})$$

$$PMI(gato, rato) = log_2(\frac{0.04}{0.05 \times 0.03})$$

$$PMI(gato, rato) = log_2(\frac{0.04}{0.0015}) = 1.415$$

- Interpretação: O PMI de 1.415 indica que "gato"e "rato"coocorrem mais frequentemente do que o esperado se fossem independentes, sugerindo uma associação semântica (o que faz sentido, pois estão relacionadas no contexto de animais).

Aplicação do PMI em Semântica Vetorial

- O PMI é usado para construir matrizes de coocorrência ponderadas, que servem como base para modelos de embeddings (representações vetoriais de palavras).
- O PMI é mencionado como uma alternativa ao TF-IDF para ponderar matrizes termo-termo (onde as dimensões são palavras, não documentos).

Utilidade

- Supera limitações da frequência bruta: Como o texto destaca, a frequência bruta (raw frequency) em matrizes de coocorrência não é discriminativa.
- Palavras comuns como "the"ou "it"coocorrem com muitas palavras, mas não indicam associações semânticas significativas.
- Captura associações semânticas: O PMI ajusta para a frequência esperada sob independência, destacando coocorrências que são mais "informativas".
- Por exemplo, "cherry"e "strawberry"podem ter um PMI alto porque coocorrem em contextos relacionados a frutas, enquanto "cherry"e "digital"terão um PMI baixo.

Questions ?